《心理学报》审稿意见与作者回应

题目：基于大语言模型的自助式 AI 心理咨询系统构建及其效果评估

作者：黄峰 丁慧敏 李思嘉 韩诺 狄雅政 刘晓倩 赵楠 李林妍 朱廷劭

第一轮

审稿人 1 意见： 基于人工智能的心理咨询是一个非常有前景的方向，这篇文章开发了一个心理咨询机器人，并通过实证研究发现机器人在改善心理健康状况方面的作用。文章具有较强的新颖性和创新性。但是，在论文写作，以及聊天机器人本身的开发过程和可能存在的问题方面，还存在一些需要作者考虑和修改的地方。具体意见如下:

意见 1：心理咨询是一项高度专业化的工作，有非常多不同的流派或取向，也有很多不同的方法技术。其中一个特别需要澄清的问题是，聊天机器人的工作是否是在做心理咨询，如果是的话，ta 又是如何做心理咨询的，主要采用哪种流派或取向，采用的技术又有哪些?貌似聊天机器人没有具体的流派或取向，只是根据被提到的问题在数据库中匹配可行的回答。

回应：感谢审稿人提出的宝贵意见。关于聊天机器人的心理咨询流派和技术取向问题，我们已在新增小节"2.1.4 流派取向设计"进行了补充说明。区别于传统的聊天机器人，大语言模型不仅仅是在数据库中匹配回答，而是具备了一定的"思维涌现"能力。因此本研究采用了多元整合的取向，在思维链提示工程中专门设计了"心理学流派应用"模块，引导模型根据用户问题类型和情绪状态动态评估并选择最合适的心理咨询流派和技术，而非局限于单一取向。该设计旨在充分发挥大语言模型的自主推理能力，提供更加个性化的心理支持。相关内容如下:

> *"针对心理咨询流派和技术取向，本研究采用了整合性策略，主要基于以下考虑: 首先，AI 辅助心理健康工作仍处于探索阶段，尚无研究表明何种单一流派更适合 AI 实施。其次，现代心理咨询实践已逐渐从严格单一流派转向整合心理治疗(Castonguay et al., 2015; Norcross & Goldfried, 2019)，整合策略能更好适应普通人群多样化的心理健康需求。最后，当前主流的 LLMs 均属于 Transformer 架构下的生成式预训练模型，其在预训练阶段已获取多种心理咨询理论知识，且已经具备一定的"思维涌现"能力(Webb et al., 2023; Wei et al., 2022)，限制其使用单一流派可能反而抑制其潜力。……本研究的提示工程设*

计理念是引导模型根据用户实时呈现的问题类型，动态地评估并选择最合适的心理咨询流派与技术。在实施上，通过思维链提示策略设计分层决策结构实现: 首先引导模型基于对话上下文分析用户问题性质(如认知扭曲、情绪困扰等)，再从所列的认知行为疗法、人本主义心理学、接纳与承诺疗法、正念疗法和焦点解决疗法等流派中选择适合的理论框架与技术。"(2.1.4 流派取向设计)

同时，我们也已将完整的提示工程文件连同本研究相关元数据一并上传至数据银行，以供同行评审以及未来研究参考和改进。匿名链接: https: //www.scidb.cn/anonymous/eklKQnpl。

意见 2: 心理健康问题和心理障碍是完全不同的。根据《中华人民共和国精神卫生法》，心理咨询人员不得进行精神障碍的诊断和治疗。那么，聊天机器人是否具备这种自觉意识，在面对可能存在精神障碍的用户时，聊天机器人能否识别并妥善提醒用户寻求专业精神科医生的帮助。特别是，如果用户存在自杀、伤人杀人或违法犯罪可能时，聊天机器人是否具备相应的应对能力。如角色指令: "请扮演心理咨询师角色与用户对话"，聊天机器人对于心理咨询师的认知就非常关键，因为 ta 对角色的定位就涉及到我这里提到的问题。即便这些问题在当前所开发的聊天机器人中还不能解决，也建议作者考虑这些点，在讨论部分中进行补充或在后续优化升级时考虑这些问题。

回应: 感谢审稿人提出的宝贵意见。在 AI 辅助心理健康的有关应用中，危机情况的处理方式和能力确实是当前内业所讨论的关键伦理难题。本研究的措施是在提示工程中设计相应的风险识别板块，当系统检测到用户可能存在施虐、自杀和自伤等严重精神障碍或其他危机情况时，会明确表示自身的局限性，并建议用户寻求专业精神科医生或心理危机干预服务的帮助(根目录>>"BOT_SYSTEM_SET">>"SYSTEM_CoT_PROMPT.josn">>"[Safety Guidelines]")。

此外，根据您的建议，我们在总讨论中增加后续优化和完善的方向。具体而言，设置额外的结构化筛查板块，以及开发人机协作模式，有可能成为未来大规模推行 AI 心理辅助时解决潜在危机和伦理难题的有效途径。相关内容如下:

".....本研究中 AI 系统在识别和处理严重心理健康问题方面仍存在局限。未来在正式部署和服务于可能存在精神障碍风险的人群时，应当着重加强 AI 系统在危机处理方面的能力，例如通过专门的风险评估模型、结构化的症状筛查工具以及与专业心理危机干预系统的无缝衔接等方式，进一步提升系统的安全性。同时，探索人机协作模式，在保持 AI 系统可及性的同时，将高风

险案例及时转介给人类专业人员进行处理，也是未来发展的重要方向。"(4.4 局限与展望)

意见 3：另一个需要解释得更清楚的问题是，聊天机器人是如何被训练出来的。作者虽然画了流程图，也给出了具体的开发步骤，但细节部分讲的不够清楚，建议作者适当举例进行说明。

回应：感谢您的宝贵意见，我们已对聊天机器人构建过程进行了更详细的说明。具体而言，在"2.1 方法"部分澄清了相关做法和原理:

"本实验使用经过大规模预训练的通用 LLMs 作为基础，通过设计思维链提示策略引导模型执行心理咨询任务，无需额外训练数据。该策略避免了获取大量真实心理咨询对话数据进行模型训练，并能够随着通用模型的迭代而持续受益。……."(2.1 方法)

同时，我们新增了一个独立小节用以补充提示工程设计的具体过程和技术细节。新增内容如下:

"首先，由一名人工智能领域研究成员(编译员)和三名国家心理咨询师资质成员(评估员)共同设计适用于单次心理咨询 AI 初始角色指令。共包含四个核心板块: (1)角色定位: 明确定义 AI 扮演的是"资深心理咨询师"角色，奠定基础定位;(2)咨询流程: 详细说明心理咨询的八个标准步骤，从建立信任到跟进评估;(3)技术应用: 列举认知行为理论、人本主义心理学和接纳与承诺疗法等九种主要心理咨询理论与技术;(4)伦理安全: 声明 AI 身份、严重问题处理原则和伦理守则。

随后，采用持续迭代优化方法逐步完善提示指令。迭代过程包括: (1)测试与反馈: 三名评估员分别对初始角色指令驱动的大模型进行对话评估，评估测试集与流程和基座模型测试环节相同，同时基于专业知识对模型响应中的不足提出具体反馈和优化建议;(2)指令调整: 编译员基于思维链提示策略将三名评估员产生的优化建议编译为新的提示模块或内容，嵌入现有提示指令;(3)迭代优化: 重复步骤 1-2，直至模型输出质量不再明显提高;(4)统计评估: 对三名评估员在初始角色指令和最新角色指令驱动下的模型对话评分执行差异检验，以评估提示工程优化效果并确定最终角色指令。……."(2.1.3 提示工程设计)

此外，为更加清晰地展示提示工程对于角色指令的优化过程，我们以"共情技巧"优化环节为例绘制了示意图。详见下图:



(正文图 2 角色指令优化过程及效果示例)

意见 4: "2.1.1 对话内容评估"部分，此处还是应该对评分准则稍作说明，而不是直接让读者去查阅附录，最好能让读者知道几个维度的例题和分数范围，并提及或介绍该评估准则的制定依据是什么。

回应: 感谢您的宝贵意见。根据建议，我们已对"2.1.1 对话内容评估"部分进行了完善，增加了对评分准则的具体说明，包括评分准则的结构、各维度的定义、评分范围以及评估依据。修订稿中明确了评分准则采用"4+1"结构，即四个能力维度和一个安全性维度，并引用了当前 AI 心理健康干预评估领域的关键研究文献作为制定依据。相关改动如下:

"……评分准则基于当前 AI 心理健康干预评估框架中的重点关注领域 (Alazraki et al., 2021; Golden & Aboujaoude, 2024; Qiaolei Jiang et al., 2022)制定，涵盖"4(能力)+1(安全)"共五个核心维度，每个能力维度采用 1-5 分的评分量表。具体包括: (1)规范性: 评估对话内容是否严格遵循心理咨询的基本规范，包括对用户的尊重、积极倾听，以及避免主观评判。(2)专业度: 评估对话内容是否展现出专业的心理健康知识与适当的咨询技巧。(3)情感理解与共情能力: 评估模型是否能够准确理解用户的情感状态，并作出适当的情感回应。(4)一致性与连贯性: 评估对话内容是否逻辑连贯，模型的回应是否在前后语境中保持一致。例如，在规范性维度中，"1 分"表示"对话内容对用户的尊重和共情表达欠缺，完全不符合心理咨询的规范要求"，而"5 分"则表示"对用户

展现了高度的尊重和共情，完全符合心理咨询的规范"。此外，基于心理咨询话题的敏感性与复杂性，评分准则还设置了"潜在有害信息"作为模型排除选项，该选项采用"是/否"二分评定及一票否决制，即任一对话内容如被任一评分者认为生成了"潜在有害信息"，则该模型被视为整体不合格。"(2.1.1 对话内容评估)

希望以上改动能够使读者能够更直观地了解本工作的评估方法和标准。再次感谢您的建议！

意见 5：根据表 1 的数据，备选基座模型在各评估维度上的得分在 5 点量表上普遍较低，最高均分也只有 2.53，说明离评分者的标准还是有较大距离。这也不免让人怀疑基于此构建的聊天机器人是否真的能达到人们的预期。作者可以不回复这个问题，但至少应该意识到这个问题。

回应：感谢审稿人的细致审阅。尽管表 1 中展示的备选基座模型初始评分偏低，但经思维链提示优化后，GPT-4o 在规范性(2.36→4.17)、情感理解与共情能力(2.53→4.08)和一致性与连贯性(2.17→3.86)方面均有显著提升(表 2)，达到 5 点量表的中上水平。

然而，我们也意识到即使在优化后，专业度维度的进步是相对有限的。鉴于你的宝贵建议，我们认真思考并再次与评分者就机器人对话表现进行了质性讨论，总体而言，评分者认为"专业度"差强人意的主要体现为: 机器人偶尔仍会表现出提供普适性心理健康建议的倾向，而非引导来访者进行自我探索和问题解决。鉴于此，我们在修订稿中增加了对此局限的澄清:

"……专业度维度(提升后均分为 2.56)的进步相对有限，主要体现为模型倾向于提供普适性建议而非引导来访者进行自我探索和问题解决，反映了当前技术在专业心理咨询能力方面的局限。"(2.3 讨论)

此外，我们也分析了背后原因，并提出相应改进方向:

"……尽管通过思维链提示优化后模型在各评估维度均有提升，但专业度方面进步相对有限，这可能与本研究中采用整合性流派策略相关。作为面向普通人群的探索性研究，整合策略增强了系统对多样化心理问题的适应性，但也可能在一定程度上牺牲了面向特定问题专业深度。未来研究可以考虑结合知识图谱，开发具体技术取向特化、针对特定心理问题的机器人，进一步提升 LLMs 在专业深度上的表现。……"(4.4 局限与展望)

意见 6：请斟酌文章题目的用词，以确定本文所开发的到底是心理咨询技术还是心理咨询程序。心理咨询技术通常指的是某些具体的心理咨询技术方法，本研究并未开发新的技术，只是构建了一个使用已有心理咨询技术的聊天机器人或者 AI 程序。并且在摘要和正文中也都提了聊天机器人。

回应：感谢您指出本工作在题目表述方面的问题，本研究确实是构建了一个基于大语言模型的自助式心理咨询系统，而非开发了新的心理咨询技术方法。我们已将文章题目修改为"基于大语言模型的自助式 AI 心理咨询系统及其效果评估"，并确保全文中的相关表述保持一致，以避免引起读者的潜在误解。再次感谢您的严谨！

意见 7：零样本推理和思维链提示策略是开发心理咨询系统的关键，应该更详细地介绍这两个方法是什么以及怎么做的，以便让读者了解这两个方法的具体工作过程，对这两个方法的评价可以略讲。

回应：感谢您的宝贵建议。在修改内容中，我们已经对零样本推理和思维链提示策略进行了更详细的介绍，明确说明了这两种方法的定义和工作机制。同时保留了对这两种方法潜在价值的简略评价，使内容更加全面且聚焦于方法的理论介绍。相关内容如下:

> *"……零样本学习是指 LLMs 在没有接受特定任务训练或示例的情况下，直接执行新任务的能力(Kojima et al., 2022)。该方法的核心机制是利用模型在预训练阶段获得的广泛知识基础和推理能力，通过精心设计的指令提示(prompt)来引导模型完成特定任务，无需额外训练数据。思维链提示策略则是一种通过引导模型分步骤思考以提升复杂推理质量的技术(Wei et al., 2022)，其核心在于模拟人类解决问题的思维过程，将复杂任务分解为多个中间推理步骤，显著提高模型在复杂推理任务中的准确率(Mitra et al., 2024; Wei et al., 2022)。"*(1.2.3 零样本学习和思维链提示策略)

意见 8：1.2 文献综述中，作者对"LLMs 技术应用于心理健康服务面临很多挑战"描述中存在很多重合的部分。例如: "然而，将人工智能技术有效应用于心理健康服务领域仍然面临诸多挑战和机遇"和下一段的"尽管大语言模型已经在多个领域取得了显著成果，但其在心理健康领域的研究和应用仍处于起步阶段"。由上文来看，这里所说的人工智能技术应该代表 LLMs，两段重合且不衔接，建议重新整理。首先，第一段，"1.2.1 LLMs 的发展及应用现状"建议改为"LLMs 及其在心理健康领域的应用现状"，该段主要是强调其在心理健康领域中的应用，应该花主要篇幅介绍。心理健康服务涉及内容甚广，包括心理健康宣传教育、心理咨询、心理疾病治疗、心理危机干预等，不应将其等同于心理咨询。另外，该段最后

一句: "鉴于此，探索 LLMs 在心理健康服务中的有效性，不仅具有重要的理论价值，也有望为满足大众日益增长的心理健康服务需求，为综合提升国民心理健康水平提供新的技术支持"为探索 LLMs 在心理健康服务中的有效性的意义，应删除。

回应：感谢您的宝贵意见。我们已对 1.2 文献综述部分进行了修改，具体包括: 1. 将 1.2.1 小节标题修改为"LLMs 及其在心理健康领域的应用现状"，并重点介绍了 LLMs 在心理健康教育、心理评估和辅助干预三个层面的具体应用; 2. 重新整合了有关 LLMs 在心理健康领域应用的内容，消除了重复描述; 3. 修改后的行文明确了心理咨询作为心理健康服务的下位概念，避免混用这两个概念; 4. 删除了原文中有关"探索 LLMs 在心理健康服务中的有效性的意义"的总结性句子，使文献综述更加聚焦于内容介绍。

意见 9: "1.2.2 大语言模型在自助式心理咨询中的潜力"部分，应该主要强调现阶段自助心理咨询的短板以及大语言模型的应用潜力，勿混合使用"心理健康"以及"心理健康领域"一词，应统一"自助式心理咨询"和"自助式 AI 心理咨询"。

回应：感谢您的宝贵建议。我们已对 1.2.2 节进行了全面修改，将标题从"大语言模型在自助式心理咨询中的潜力"调整为"自助式 AI 心理咨询的潜力与挑战"。鉴于现阶段尚无研究正式提出"自助式心理咨询"这一概念，我们在此节内容上更加聚焦于现阶段心理健康服务的两种主要形式(包括专业人员提供的心理咨询和非互动式自助资源)及其局限性:

> *"目前心理健康服务主要包括专业人员提供的心理咨询和非互动式自助资源(如心理健康书籍、音频、视频课程等)。专业心理咨询广受认可，但面临资源稀缺、成本高昂和地域限制等问题(Patel et al., 2016; Saxena et al., 2007; Sun et al., 2024)。据统计，全球范围内的心理健康专业人员与其区域人口基数比例都处于严重失衡状态(Bruckner et al., 2011; Singla et al., 2018)；在中国，每十万人口对应的精神健康专业人员(包括精神科医生/护士、临床心理学家、咨询心理学家、心理康复治疗师和相关社会工作者等)不到 3 人(Sun et al., 2024)。同时，地域分布不均、服务成本高昂和社会污名化等因素进一步限制了专业心理咨询的普及(Sun et al., 2024; Yu et al., 2018)。书籍、视频和应用程序等非互动式自助心理健康资源虽然具有高可及性、低成本和易传播的优势，但存在交互有限、个性化不足等问题。……"*(1.2.2 自助式 AI 心理咨询的潜力与挑战)

在此基础上，正式引出基于 LLMs 的自助式 AI 心理咨询，并介绍了其潜力和挑战:

> *"……基于 LLMs 的自助式 AI 心理咨询有望弥补当前心理健康服务的缺口，在保持高可及性和低成本优势的同时，为难以获得传统心理咨询服务的人群*

提供类似专业咨询的互动体验。然而，构建有效的自助式 AI 心理咨询系统面临两个核心技术挑战：一是如何在真实心理咨询数据稀缺的条件下优化模型性能；二是如何设计有效的人机交互方式，使用户能够建立类似于传统心理咨询中的治疗关系。"(1.2.2 自助式 AI 心理咨询的潜力与挑战)

此外，我们在修订稿中统一了术语使用，避免混用"心理健康"和"心理健康领域"等泛化表述，一致采用"自助式 AI 心理咨询"。再次感谢您的宝贵建议。

意见 10：引言中并未阐述研究"AI 咨询师拟人化设计"的依据和必要性。

回应：感谢您的宝贵意见。我们在修改稿中新增了"1.2.4 拟社会互动理论与 AI 拟人化设计"一节。系统介绍了该理论为作为 AI 拟人化设计的理论基础，以及其在自助式 AI 心理咨询设计中的潜在价值和研究必要性。新增小节首先介绍了拟社会互动理论的起源及其在人机交互领域的应用，解释了人们如何将数字代理视为社会行为体并建立情感连接；其次，详细阐述了拟人化设计(人类姓名、性别和视觉图像)如何通过增强社会存在感，提高用户对数字工具的信任度，进而可能影响心理咨询效果；最后，我们提出拟人化设计可能对不同类型的心理健康问题产生差异化影响的理论假设，进而为本研究的实验二提供理论依据。

意见 11：研究一的题目是"基于 LLMs 和提示工程的自助式心理咨询系统构建"，而本文的题目是"基于大语言模型的……"，应斟酌用语。

回应：感谢您的宝贵意见。结合您的下一条建议，我们在修订稿中将原有研究一修改为"实验 1：构建基于大语言模型的自助式心理咨询系统"，确保与全文标题"基于大语言模型的自助式 AI 心理咨询系统构建及其效果评估"在术语使用上保持一致。再次感谢您的宝贵意见！

意见 12：研究一、二的前言部分应缩减，与综述部分进行合并修改，请参考学报既往文章格式。

回应：感谢您的宝贵建议。我们已按照建议对文章结构进行了优化调整，具体而言：

1). 参考学报既往文章，将原"研究一/二"重命名为"实验一/二"，并大幅精简了各实验的前言部分。2). 将相关理论内容整合至综述部分。在重组后的"1.2 文献综述"部分，系统介绍了 LLMs 在心理健康领域的应用现状(1.2.1 小节)、自助式 AI 心理咨询的潜力与挑战(1.2.2 小节)、零样本学习和思维链提示策略(1.2.3 小节；呼应前文挑战一)以及拟社会互动理论与

AI 拟人化设计(1.2.4 小节; 呼应前文挑战二)。3). 各实验部分则直接聚焦于具体研究目的和实验设计，避免与文献综述重复。

意见 13: 3.1.1 参与者的描述部分，"(2)已经被心理医生或专业机构诊断为存在严重心理健康问题的个体"，何为"严重心理健康问题"?

回应: 感谢您提出疑问。关于"严重心理健康问题"的定义，我们已根据研究中实际使用的问卷内容进行了明确界定，并优化了表述的严谨性和专业性。修改后的内容明确指出了排除标准中"严重心理健康问题"指自杀意念、自我伤害行为、施虐倾向等，同时也明确了所排除的精神障碍类型。相关内容如下:

> *"……参与者排除标准包括: (1)18 周岁以下未成年人;(2)自认为或曾被医生/专业机构诊断为存在严重心理健康问题(如自杀意念、自我伤害行为、施虐倾向等)或患有精神障碍(包括但不限于抑郁症、双相情感障碍、精神分裂症等)的个体。"*(3.1.1 参与者)

意见 14: 人机互动部分，对参与者与机器人交流互动的次数是否有限制? 如何确保参与者完成交互，而非仅仅做了问卷?

回应: 感谢您提出的问题。在此前的分析中，我们对于人机互动的质量控制仅基于后台统计有活跃记录的参与者，即只要参与者完成 T1 问卷并受邀进入企业微信与自助咨询机器人进行了聊天，则被纳入分析。受贵意见启发，我们在修订稿中增强了对于人机交互的质量控制措施: 仅将人机交互期间至少与机器人进行 10 轮次以上对话，且对话时间跨度在 10 分钟以上的用户被视为有效互动。按此标准控制后，T2 时间点保留 180 名参与者数据，T3 时间点保留 153 名参与者数据。且质量控制后发现压力模型的交互作用由原本的不显著变为边缘显著($p = 0.05$)。进一步分析发现，仅非拟人化设计(R 组)对压力缓解有效。其他统计结果(各变量系数方向、显著性等)未发生改变，主要结论与此前保持一致。我们在修订稿中增加了对于质量控制的澄清以及对压力结果的讨论。部分原文如下:

> *"……为确保参与者积极参与实验，本实验要求参与者尽量每日与机器人进行对话，并将参与者与机器人进行 10 轮次对话、且对话时间跨度大于 10 分钟的当日标记为互动日。后续分析中将互动日大于 0 的参与者视作有效交互，否则归入流失样本。"(3.1.2 实验设计)*

> *"……压力模型中，组别×时间交互效应达到边缘显著水平($\chi^2(6) = 12.53, p = 0.05$)；模型的解释力相对较低(3%)。"*(3.2.2 线性混合模型)

"…… 压力指标呈现出显著的组别差异: 仅 R 组从 T1 到 T2 表现出显著降低(b = 2.35, SE = 0.48, p < 0.001)，但在 T3 时回归至与 T1 无显著差异(p = 0.30); F 组、M 组和对照组在各时间点间均无显著变化(所有 p ≥ 0.17)。"(3.2.3 简单效应分析)

"图 4C 显示了压力指标的变化: T1 时各组间无显著差异; T2 时，仅 R 组与对照组的差异达到边缘显著(b = 2.00, SE = 0.85, p = 0.09)，其余组别间差异均不显著(所有 p > 0.42); T3 时，各组间无显著差异(所有 p ≥ 0.82)。"(3.2.4 Tukey HSD 多重比较)

"…… 与孤独感形成对比的是压力指标的结果。本研究发现，仅非拟人化机器人显示出对压力指标的显著改善效果。这种差异模式可能源于压力的主要来源及其与社会评价的特殊关系。压力通常来自于对情境的评估和应对资源的感知，而社会评价本身就是一种强大的压力源。正如 Cavanagh 和 Allen(2008)研究所示，社会评价情境会激活下丘脑-垂体-肾上腺轴(HPA 轴)，这是人体主要的生理压力反应系统，负责释放皮质醇等压力激素。在非拟人化设计中，减少了交互对象的社会属性，可能降低了社会评价压力的突显性。参与者面对没有人类特征的机器人时，可能体验到更少的"被评判感"，从而能够更加开放地讨论压力问题本身，而不必担心如何在社交互动中表现自己。这种评价中立的环境可能特别有利于压力管理，因为它消除了一个额外的压力源(社会评价)，使参与者能够更有效地关注和处理原有的压力问题。这一发现表明，在处理压力这一特定心理健康问题时，降低人机交互的拟人化元素可能创造更有效的治疗环境。"(4.3 拟人化设计对不同心理健康指标的差异化影响)

意见 15：在研究二的引言部分，作者明确说本研究的创新体现在哪些方面。一般期刊论文很少这样写。所以，这里不用说本研究的创新，而是继续论述本研究拟解决的问题就行，这样研究创新或研究意义就自然体现出来了。

回应：感谢您的宝贵建议，我们在修订稿中移除了相关表述，更加聚焦于论述本研究拟解决的问题，即在不依赖大量真实数据的前提下，基于 LLMs 开发并评估自助式 AI 心理咨询系统。

意见 16：研究二的样本为 202 人，请解释一下样本量的确定依据。

回应： 感谢您的宝贵建议。我们在修订稿中汇报了基于先验统计功效分析确定计划样本量的过程，相关内容如下:

> *"本实验通过基于先验统计功效分析确定样本量。采用 simr 包(Green & MacLeod, 2016)进行 4(组别)×3(波次)混合设计的功效分析，针对组别×波次交互效应进行蒙特卡洛模拟。短期干预效应(T2)参考 Păsărelu 等人(2017)对互联网认知行为疗法的元分析，设置为中到大效应(d = 1.1-1.5)；长期效应(T3)参考 Firth 等人(2017)关于智能手机心理健康干预的元分析，设置为小效应(d = 0.2-0.3)。采用含随机截距的 LMM，设置目标检验力(1-β = 0.80)和 α = 0.05 的显著性水平，进行 1000 次模拟。模拟结果表明每组参与者达到 37 人(总样本量 148 人)时，可获得满足要求的统计功效。考虑三波次纵向设计 25%左右的预期样本流失率，计划每组分配样本量 50 人，总样本量 200 人。实际通过在线平台招募参与者 202 人……"*(3.1.1 参与者)

意见 17： 分讨论的内容可以适当压缩，总讨论显得有些单薄。特别是研究局限和未来研究方向部分，可以再丰富些，比如每个大点下面给出适当的解释。特别是局限部分，文章还应该讨论聊天机器人本身功能的局限，我在前面的意见已提到过。

回应：感谢您的宝贵建议。在修订稿中，我们已参照学报往期文章格式大幅调整了讨论部分的结构，将原先分散在研究一和研究二中的讨论内容整合到总讨论部分，形成了更为系统的论述。总体而言，新的总讨论章节包括四个小节: 4.1 提示工程在心理健康服务中的应用价值; 4.2 自助式 AI 心理咨询对不同心理健康指标的效果; 4.3 拟人化设计对不同心理健康指标的差异化影响; 以及 4.4 局限与展望。

针对局限性讨论单薄的问题，我们在第 4.4 节中显著扩充了内容，具体涵盖: (1)究周期短期性问题及其对评估长期效果的限制;(2)样本组成的局限性及其对结果普适性的影响;(3)AI 系统在专业度方面的局限，特别是在引导深度自我探索方面的不足;(4)AI 系统在识别和处理严重心理健康问题方面的局限。

……

审稿人 2 意见:

本文探讨了基于大语言模型的自助式心理咨询系统的构建及其实际应用效果，选题具有重要的理论价值和现实意义。研究设计合理，数据分析方法恰当，结果具有一定的创新性。然而，论文在组织架构、理论阐述和结果呈现等方面仍存在需要改进的地方。组织架构与理论基础:

意见 1：本文在结构组织方面存在重复和碎片化问题。研究一和研究二的前言部分与总引言部分存在内容重叠，建议对这些内容进行系统整合。具体而言，对于大语言模型的发展现状、AI 在心理健康领域的应用等共性内容应统一移至总体文献综述部分，而各子研究的前言则应聚焦于该研究特有的理论基础和研究问题。同样的问题也出现在两个子研究的讨论部分，建议采用类似的整合策略，避免不必要的重复。

回应：感谢审稿人的宝贵意见。针对您指出的结构组织问题，我们对论文进行了全面的架构调整: 首先，我们参照学报既往文章格式重新组织了整体结构，将原"研究一/二"表述为"实验一/二"。而后，我们对引言、实验前言和讨论部分进行了系统整合，具体而言:

1) 引言和文献综述部分: 将原分散在总引言和各子研究前言中的理论内容整合至综述部分。重组后的"1.2 文献综述"系统呈现了四个相互关联的小节: LLMs 在心理健康领域的应用现状(1.2.1)、自助式 AI 心理咨询的潜力与挑战(1.2.2)、零样本学习和思维链提示策略(1.2.3)以及拟社会互动理论与 AI 拟人化设计(1.2.4)。
2) 实验部分调整: 大幅精简了各实验的前言内容，使其直接聚焦于具体研究目的和实验设计，避免与文献综述部分的重复。
3) 讨论部分重构: 将原先分散在研究一和研究二中的讨论内容整合到总讨论部分，形成更系统、深入的论述，避免了之前的碎片化问题。

意见 2：论文需要明确说明采用了何种心理咨询理论取向，并解释如何将特定流派的理论原则转化为提示工程的具体策略。同时，还应该阐述选择该理论取向的合理性，以及这种选择对研究结果的潜在影响。

回应：感谢您的宝贵建议。我们已在论文中新增"2.1.4 流派取向设计"小节，详细说明了提示工程中对于心理咨询理论取向的选择、实施方法及合理性。相关内容如下:

> *"……本研究采用了整合性策略，主要基于以下考虑: 首先，AI 辅助心理健康工作仍处于探索阶段，尚无研究表明何种单一流派更适合 AI 实施。其次，现代心理咨询实践已逐渐从严格单一流派转向整合心理治疗(Castonguay et al., 2015; Norcross & Goldfried, 2019)，整合策略能更好适应普通人群多样化的心理健康需求。最后，当前主流的 LLMs 均属于 Transformer 架构下的生成式预训练模型，其在预训练阶段已获取多种心理咨询理论知识，且已经具备一定的"思维涌现"能力(Webb et al., 2023; Wei et al., 2022)，限制其使用单一流派可能反而抑制其潜力。*

本研究的提示工程设计理念是引导模型根据用户实时呈现的问题类型，动态地评估并选择最合适的心理咨询流派与技术。在实施上，通过思维链提示策略设计分层决策结构实现：首先引导模型基于对话上下文分析用户问题性质(如认知扭曲、情绪困扰等)，再从所列的认知行为疗法、人本主义心理学、接纳与承诺疗法、正念疗法和焦点解决疗法等流派中选择适合的理论框架与技术。"(2.1.4 流派取向设计)

同时，在讨论部分我们也补充了这种整合策略对研究结果的潜在影响，指出它增强了系统对多样化心理问题的适应性，但可能在一定程度上影响了专业深度的提升。有关内容如下:

"……尽管通过思维链提示优化后模型在各评估维度均有提升，但专业度方面进步相对有限，这可能与本研究中采用整合性流派策略相关。作为面向普通人群的探索性研究，整合策略增强了系统对多样化心理问题的适应性，但也可能在一定程度上牺牲了面向特定问题专业深度。未来研究可以考虑结合知识图谱，开发具体技术取向特化、针对特定心理问题的机器人，进一步提升 LLMs 在专业深度上的表现。"(4.4 局限与展望)

意见 3：作者在引言中提到拟社会互动理论，对于该理论的应用需要更深入的阐述。建议深入说明该理论在 AI 心理咨询场景中的适用性，例如，为什么预期 AI 咨询师的拟人化程度会影响干预效果？同时，在后续的讨论部分应当基于研究结果对这些理论假设进行验证和讨论。

回应：感谢您的宝贵建议。我们已在引言中新增"1.2.4 拟社会互动理论与 AI 拟人化设计"小节，深入阐述了该理论在 AI 心理咨询场景中的适用性。具体而言，我们从理论起源出发，解释了准社会交往如何从传统媒体扩展到人机交互领域，并详细论述了拟人化设计通过增强社会存在感影响用户体验的机制，并预测了其对不同心理健康问题可能产生的差异化影响。

"拟社会互动理论(parasocial theory; Stever, 2017)为理解用户与 AI 咨询师之间的心理连接提供了理论基础，对优化自助式 AI 心理咨询系统的设计与效果具有重要指导意义。拟社会互动（Parasocial interaction, PSI）最初由 Horton 和 Wohl(1956)提出，用来解释受众与大众媒体人物之间形成的单向但情感丰富的关系。随着数字技术的发展，这一理论已被扩展应用于人机交互领域，解释用户如何与数字代理(如虚拟助手、聊天机器人等)建立社会性连接(Giles, 2002; R. Tukachinsky et al., 2020)。该理论指出，即使在非对称的交流中，人们也倾向于将数字代理视为社会行为体，并对其应用社交规则和期望(Noor et al., 2021; R. Tukachinsky et al., 2020)。

在自助式 AI 心理咨询的设计中，拟人化程度(如是否赋予 AI 咨询师姓名、性别、人类视觉形象等社会属性)可能显著影响用户的拟社会体验和互动质量。研究表明，拟人化设计可以增强用户感知到的社会存在感(social presence; Konya-Baumbach et al., 2022; Munnukka et al., 2022; Toader et al., 2019)，而这种社会存在感的增强能够提高用户对数字工具的信任度(Hassanein & Head, 2007; Toader et al., 2019)。在心理咨询情境中，这种社会存在感和信任度和对于用户与 AI 咨询师之间的治疗关系建立至关重要。此外，拟人化设计可能对不同类型的心理健康问题产生差异化影响。例如，对于孤独感等与人际关系缺失相关的问题，拟人化的 AI 咨询师或将通过提供更强的社会存在感，进而比非拟人化设计产生更显著的缓解效果。……"(1.2.4 拟社会互动理论与 AI 拟人化设计)

同时，我们也在讨论部分(4.3 节)中基于研究结果对以上理论假设进行了验证和扩展，并提出了一个未来研究中基于问题性质(社会功能 vs. 问题解决)的差异化设计框架。部分原文如下:

"……基于以上发现，本研究可以提出一个差异化设计框架: 对于以改善社会功能为主要目标的干预(如针对孤独感)，拟人化设计可能通过提供类社交体验而特别有效; 而对于以解决具体问题为主要目标的干预(如压力管理)，非拟人化设计可能通过减少社交压力而创造更有利的思考环境。该理论框架丰富了现有人机交互研究中对于心理机制的理解，也为 AI 辅助心理健康服务的精准设计提供了实证基础。"(4.3 拟人化设计对不同心理健康指标的差异化影响)

意见 4: 建议加强对压力指标未见显著改善原因的讨论，可以从压力的多维度特性角度展开分析。同理，应当更加深入地探讨焦虑症状改善效果具有持续性的原因及其理论意义，以及讨论拟人化设计对不同心理健康指标影响差异的可能机制。这些深入分析将大大提升研究的理论贡献。

回应: 感谢您的宝贵建议。结合后续意见 14，在实施交互质量控制(对话 10 轮次以上、且时间跨度超过 10 分钟)后，我们发现压力指标的组别×时间交互效应达到边缘显著水平($p = 0.05$)。进一步分析揭示了一个有趣的现象: 仅非拟人化设计(R 组)对压力指标显示出显著改善效果，这与拟人化设计更有效缓解孤独感形成鲜明对比。鉴于此，我们在修订稿 4.3 节中增加了对这一差异化效应的深入讨论，探讨了压力与社会评价的特殊关系:

"…… 与孤独感形成对比的是压力指标的结果。本研究发现，仅非拟人化

机器人显示出对压力指标的显著改善效果。这种差异模式可能源于压力的主要来源及其与社会评价的特殊关系。压力通常来自于对情境的评估和应对资源的感知，而社会评价本身就是一种强大的压力源。正如(Cavanagh & Allen, 2008)研究所示，社会评价情境会激活下丘脑-垂体-肾上腺轴(HPA 轴)，这是人体主要的生理压力反应系统，负责释放皮质醇等压力激素。在非拟人化设计中，减少了交互对象的社会属性，可能降低了社会评价压力的突显性。参与者面对没有人类特征的机器人时，可能体验到更少的"被评判感"，从而能够更加开放地讨论压力问题本身，而不必担心如何在社交互动中表现自己。这种评价中立的环境可能特别有利于压力管理，因为它消除了一个额外的压力源(社会评价)，使参与者能够更有效地关注和处理原有的压力问题。这一发现表明，在处理压力这一特定心理健康问题时，降低人机交互的拟人化元素可能创造更有效的治疗环境。"(4.3 拟人化设计对不同心理健康指标的差异化影响)

关于焦虑改善效果的持续性，我们在 4.2 节中也增加了理论分析:

"……焦虑症状的改善在一周后随访中仍然保持显著，表现出良好的持续性；而抑郁症状和孤独感的改善效果则在随访中回归至接近基线水平。焦虑症状持续改善的特殊性可能与其认知特性相关——焦虑常源于对未来威胁的过度预期(Liu et al., 2024)，AI 系统通过提供即时、系统性的认知调整框架，可能有效打破了焦虑的自我强化循环。这种认知层面的调整一旦形成，其效果往往比情绪或行为层面的变化更为持久(Rafferty & Minbashian, 2018; Snippe et al., 2024)。相比之下，抑郁和孤独感可能更多涉及深层社会功能和长期行为模式，仅靠短期干预难以维持长久效果。"(4.2 自助式 AI 心理咨询对不同心理健康指标的效果)

意见 5：研究一中的评分准则开发过程需要更详细的说明。目前的描述缺乏评分准则的理论依据、具体的制定流程和专家咨询过程。建议补充评分标准的操作性定义，以及评分者培训方案。

回应：感谢您的宝贵意见。我们已对"2.1.1 对话内容评估"部分进行了全面修改，补充了制定评分准则的依据、具体维度内容与操作性定义等细节。修改后的内容明确说明了评分准则是基于当前相关研究，涵盖"4+1"共五个核心维度，每个能力维度采用 1-5 分的量表，并提供了各维度的详细定义及评分标准示例:

"……根据提前制定的《AI 心理咨询对话质量评估准则》(下文称"评分准则")对模型生成的内容进行独立打分，并通过组内相关系数(ICC)评估评分者

一致性。该评分准则基于当前 AI 心理健康干预评估框架中的重点关注领域(Alazraki et al., 2021; Golden & Aboujaoude, 2024; Qiaolei Jiang et al., 2022)制定，涵盖"4(能力)+1(安全)"共五个核心维度，每个能力维度采用1-5 分的评分量表。具体包括: (1)规范性: 评估对话内容是否严格遵循心理咨询的基本规范，包括对用户的尊重、积极倾听，以及避免主观评判。(2)专业度: 评估对话内容是否展现出专业的心理健康知识与适当的咨询技巧。(3)情感理解与共情能力: 评估模型是否能够准确理解用户的情感状态，并作出适当的情感回应。(4)一致性与连贯性: 评估对话内容是否逻辑连贯，模型的回应是否在前后语境中保持一致。例如，在规范性维度中，"1 分"表示"对话内容对用户的尊重和共情表达欠缺，完全不符合心理咨询的规范要求"，而"5 分"则表示"对用户展现了高度的尊重和共情，完全符合心理咨询的规范"。此外，基于心理咨询话题的敏感性与复杂性，评分准则还设置了"潜在有害信息"作为模型排除选项，该选项采用"是/否"二分评定及一票否决制，即任一对话内容如被任一评分者认为生成了"潜在有害信息"，则该模型被视为整体不合格。"(2.1.1 对话内容评估)

此外，由于三名评估者全程共同参与了评分准则的制定，此过程中已确保对各维度标准的一致理解和应用，因此我们通过报告后验 ICC 检验评分者一致性:

> *"……三位评分者对每条材料进行独立评分的组内相关系数(ICC)为 0.709($F(35, 105) = 2.441, p < 0.001$)，表明评分者间具有良好的一致性。"*(2.2.1 模型选择)

意见 6: 研究一中基座模型的评估使用了 12 条测试用例，对于测试样例的主题确定和抽取标准具体如何？作者应当在样例选择标准和代表性方面提供更多细节。

回应: 感谢您的宝贵意见。我们已补充了测试样例来源、主题范围、抽取标准和代表性说明。在修改中，我们详细列出了《心理健康对话数据集》中包含的 12 个常见心理咨询主题类别，明确了采用分层随机抽样的方法从每个主题类别中选取测试案例，并提供了测试案例的示例:

> *"……本研究从 Chen 等人(2023)构建的《心理健康对话数据集》中选取测试样例。该数据集包含人际、家庭和成长等 12 个主题类别。为确保测试集的代表性，采用分层随机抽样方法从每个主题类别中随机抽取 1 条具体案例作为测试集。测试案例的内容形式为用户向咨询师表达的初次问题描述，如"最近有点失望，觉得友情很脆弱"(人际)、"爸妈离异，我感到很难过"(家庭)、"*

我总觉得自己不自信，不知道该怎么办"(成长)等。测试集构建完成后，基于简单角色指令("请扮演心理咨询师角色与用户对话")引导基座模型进行 10 轮次(一问一答)对话，形成对话评估材料。最后，基于评估小组对各基座模型生成的对话内容评结果，通过方差分析确定最佳基座模型。"(2.1.2 基座模型测试)

意见 7：研究一中提示工程的构建作为本项研究的关键操作，建议在附录中补充完整的提示工程内容，包括提示策略的设计原则和优化迭代的具体过程。这些信息对于研究的可重复性具有重要意义，同时也能为相关领域的研究者提供有益参考。

回应：感谢您的宝贵建议。鉴于文件体量和格式类型，我们已将完整的提示工程文件和模型参数设置上传至数据银行(匿名链接: https: //www.scidb.cn/anonymous/eklKQnpl)。该文件将随论文及相关数据集一并在线发布，以确保研究的可重复性并为相关领域研究者提供参考。

同时，我们也在修改稿正文"2.1.3 提示工程设计"部分增加了详细的设计过程说明:

"……首先，由一名人工智能领域研究成员(编译员)和三名国家心理咨询师资质成员(评估员)共同设计适用于单次心理咨询 AI 初始角色指令。共包含四个核心板块: (1)角色定位: 明确定义 AI 扮演的是"资深心理咨询师"角色，奠定基础定位;(2)咨询流程: 详细说明心理咨询的八个标准步骤，从建立信任到跟进评估;(3)技术应用: 列举认知行为理论、人本主义心理学和接纳与承诺疗法等九种主要心理咨询理论与技术;(4)伦理安全: 声明 AI 身份、严重问题处理原则和伦理守则。

随后，采用持续迭代优化方法逐步完善提示指令。迭代过程包括: (1)测试与反馈: 三名评估员分别对初始角色指令驱动的大模型进行对话评估，评估测试集与流程和基座模型测试环节相同，同时基于专业知识对模型响应中的不足提出具体反馈和优化建议;(2)指令调整: 编译员基于思维链提示策略将三名评估员产生的优化建议编译为新的提示模块或内容，嵌入现有提示指令;(3)迭代优化: 重复步骤 1-2，直至模型输出质量不再明显提高;(4)统计评估: 对三名评估员在初始角色指令和最新角色指令驱动下的模型对话评分执行差异检验，以评估提示工程优化效果并确定最终角色指令。"(2.1.3 提示工程设计)

此外，我们也新增了图 2 以展示了角色指令优化过程及效果示例，直观呈现了提示工程如何优化模型输出:



(正文图 2 角色指令优化过程及效果示例)

意见 8：研究二的样本量确定缺乏必要的统计学依据，需要补充样本量的先验计算过程，包括效应量估计的依据，以及分组设计中样本量分配的考虑因素。

回应：感谢您的宝贵建议。在修订稿中，我们增加了详细的样本量确定依据，包括效应量估计来源、功效分析方法及结果。相关内容如下：

> *"本实验通过基于先验统计功效分析确定样本量。采用 simr 包(Green & MacLeod, 2016)进行 4(组别)×3(波次)混合设计的功效分析，针对组别×波次交互效应进行蒙特卡洛模拟。短期干预效应(T2)参考 Păsărelu 等人(2017)对互联网认知行为疗法的元分析，设置为中到大效应(d = 1.1-1.5)；长期效应(T3)参考 Firth 等人(2017)关于智能手机心理健康干预的元分析，设置为小效应(d = 0.2-0.3)。采用含随机截距的 LMM，设置目标检验力(1-β = 0.80)和 α = 0.05 的显著性水平，进行 1000 次模拟。模拟结果表明每组参与者达到 37 人(总样本量 148 人)时，可获得满足要求的统计功效。考虑三波次纵向设计 25%左右的预期样本流失率，计划每组分配样本量 50 人，总样本量 200 人。实际通过在线平台招募参与者 202 人……"*(3.1.1 参与者)
>
> *"…… 参与者从 T1 到 T3 的总流失率为 24.3%，符合预期设计。"*(3.2.1 描述统计)

意见 9：研究二中 T2 时间点的测量安排在"互动阶段的最后两天"，该时间安排的考虑是什么？或者说，为什么不在互动结束后立即测量?

回应：感谢您的细致审阅。关于 T2 时间点的测量安排，我们有以下考量:

(1) 为构建低负荷的自然实验环境，所有测量均通过在线方式(邮件+短信)推送。考虑到参与者多为上班族和学生，周末测量有助于提高问卷完成率和数据质量。

(2) T1 基线测量的时间窗口为周六至周日两天。为确保测量条件一致性并控制工作日与周末的心理状态差异，我们将三次测量(T1、T2 和 T3)均安排在相同时间段进行。

(3) 鉴于实验周期较长，提供两天的填写窗口可减轻参与者负担，提供更灵活的参与方式，从而更好地模拟自然使用情境下的心理健康评估。

基于您的宝贵意见，我们已在修改稿中针对测量时间窗口进行了必要说明:

> *"……为提高问卷完成率和数据质量，以及控制时间因素导致的潜在测量偏差(如工作日与周末的心理状态差异)，三次问卷的填写时间均被设置在周六至周日。"*(3.1.2 实验设计，'数据采集')

意见 10：研究二是否有采用必要措施对于交互数据进行质量控制？例如，对参与者与机器人交互次数的要求和限制？这些细节对于评估研究的内部效度至关重要。

回应：感谢您提出的重要问题。在修订稿中，我们采用了明确的交互质量标准: 参与者需要与机器人进行至少 10 轮次的对话，且对话时间跨度超过 10 分钟，才被标记为有效互动日。我们在 3.1.2 实验设计部分补充说明:

> *"……为确保参与者积极参与实验，本实验要求参与者尽量每日与机器人进行对话，并将参与者与机器人进行 10 轮次对话、且对话时间跨度大于 10 分钟的当日标记为互动日。后续分析中将互动日大于 0 的参与者视作有效交互，否则归入流失样本。"*(3.1.2 实验设计)

经此标准筛选后，T2 时间点共保留 180 名参与者数据(保留率 89.11%)，不同组别的有效交互比例分别为 C 组 88.0%、F 组 94.1%、M 组 92.2%、R 组 90.0%，组间差异不显著($\chi^2(3) = 1.75$，$p = 0.63$)，表明各组参与者的交互参与度相当。此外，质量控制措施后压力模型的交互效应从不显著变为边缘显著($p = 0.05$)，进一步分析发现非拟人化设计(R 组)对压力缓解有显著效果。我们在修订稿中更新了相关结果，并结合意见 4，在"4 总讨论 >> 4.3 拟人化设计对不同心理健康指标的差异化影响"小节对上述结果进行了详细讨论。

意见 11：研究二中流失样本处理。建议补充流失样本的人口统计学特征分析，评估是否存在系统性差异，并详细说明缺失数据的处理方法。考虑进行敏感性分析，以评估样本流失对研究结果的潜在影响。

回应：非常感谢您的专业建议。我们已在修订稿中补充了流失样本的详细分析，相关内容如下:

> *"……参与者从 T1 到 T3 的总流失率为 24.3%，符合预期设计。对完成全部测试的参与者与至少有一次测评缺失的参与者在人口统计学特征和基线心理健康指标上进行比较分析，结果显示，完成三次测量的参与者与至少一次测评缺失者在年龄($t(70.25) = 1.78$，$p = 0.08$)、性别($\chi^2(1) = 0.33$，$p = 0.56$)、基线抑郁水平($t(73.66) = 1.95$，$p = 0.06$)、焦虑水平($t(86.50) = 0.94$，$p = 0.35$)、压力水平($t(86.36) = 0.91$，$p = 0.36$)和孤独感($t(91.85) = 1.51$，$p = 0.13$)方面均无统计学显著差异。各组的有效交互比例分别为 C 组 88.0%、F 组 94.1%、M 组 92.2%、R 组 90.0%，组间差异不显著($\chi^2(3) = 1.75$，$p = 0.63$)"*(3.2.1 描述统计)

同时，我们也补充说明了对于缺失数据处理说明以及敏感性检验:

> *"LMM 能有效处理纵向数据中的缺失值，在数据缺失完全随机(MCAR)或随机(MAR)的情况下提供无偏估计。为进一步评估样本流失对研究结果的潜在影响，我们分别使用完整样本(包含所有至少参与一次测量的参与者，$n = 202$)和限制样本(仅包含完成全部三次测量的参与者，$n = 153$)进行了模型拟合。比较结果显示，两种分析方法得出的关键参数估计在符号和统计显著性上保持一致，表明缺失数据对研究结论的影响有限。本文报告的结果基于完整样本分析。"*(3.1.5 敏感性检验)

意见 12：应当补充所采用 DASS-21 和 SSL 量表在中国人群中的信效度数据，两个量表的计分方式应尽可能详细一些，例如，在 SSL 中，1 和 5 分别代表什么，需要解释清楚。另外，内部一致性信度和克伦巴赫 α 系数是两个不同的概念，不要混用。

回应：感谢您的宝贵建议。我们已在修订后的正文中补充了 DASS-21 和 SSL 量表在中国人群中的信效度数据，并引用了对相应量表在中国样本中验证的研究结果(Gong et al., 2010; Jiang, Zhao, et al., 2022)，包括内部一致性系数、建构信度和效标效度等信息。同时，我们在修订稿中更加详细地说明了两个量表的计分方式。此外，修订稿中已统一表述，明确使用"Cronbach's α 系数"来表示内部一致性信度的具体数值。(3.1.3 测量工具)

意见 13：摘要部分，不建议出现 β、95%CI 和 p 等统计符号。

回应：感谢您的宝贵建议。我们已经在修订稿中更新了摘要部分，包括移除 β、95%CI 和 p 等统计符号和具体数据。

意见 14： 表 1 和表 2 的标题应简化，建议删除括号里的内容; 表内，95%CI 代表的是哪个参数或统计量的置信区间，需要交代清楚; 表 1 中关于上标字母 a 和 b 的解释含糊不清; 建议在表 1 中补充方差分析的效应量。

回应：感谢您的宝贵建议。我们在修订稿中进行了以下优化: (1). 对表 1 和表 2 的标题进行简化，并补充了表内置信区间的具体说明;(2). 改进了表 1 中关于上标字母 a 和 b 的解释，并辅以具体示例;(3).在表 1 中补充 η^2作为方差分析的效应量。部分内容如下:

> *"括号内数值为标准差。同一行中不同的上标字母(^{a}, ^{b})表示在 Tukey HSD 事后检验中存在显著差异($p < 0.05$)，以总分为例，GPT-4o 上标为 b、后两者上标为 a，表示前者均值显著高于后两者，而后两者之间差异不显著。η^2为效应量。F 值的自由度为(2, 105)。置信区间为组间均值差异的 95%置信区间。……"*(表 1 注)

> *"括号内数值为标准差。d 值为 Cohen's d 效应量。t 值的自由度为 35。置信区间为提示工程与简单指令均值差异的 95%置信区间。……"*(表 2 注)

意见 15： 研究二中的样本量是 202 还是 533，前后矛盾。表 3 中年龄的均值和标准差与上一段的文字描述也存在差异。表 3 中，性别应编码为 0 和 1，这样计算均值和标准差才有意义。

回应：感谢指出该表述问题。在原稿研究二中，202 为参与者数量，而表格中 $N = 533$ 为拟合线性混合模型时自动输出的观测样本量(*N(obs)*; 长数据排列)。相应地，原稿文字描述中的年龄、性别比均为全体初始参与者描述性统计，而表格中则为 LMM 建模时自动输出的长数据描述性统计。

基于您的宝贵建议，我们已在修订稿中优化实验二的数据描述，使其更符合纵向研究规范。包括: (1).描述性统计和相关分析均采用分波次汇报(表 3; 0 = 女性,1 = 男性); (2). LMM 汇总表中注明了分波次样本量 *n* 和总观测量 *N*。

此外，结合您的宝贵意见 10 和 11，我们在进行质量控制后分别构建了两份数据以供模型敏感性检验: (1).全样本数据: 由于 LMM 可以处理非平衡纵向数据，纳入 T1-T3 时间点全部可用样本(N(观测数) = 535; n(T1) = 202, n(T2) = 180, n(T3) = 153)。正文报告基于此数据。(2). 平衡面板数据: 仅包含完成全部三次测试参与者数据样本(N(观测数) = 459; n = 153, t = 3)，此数据用于模型敏感性检验。基于两种样本的关键参数估计在符号和统计显著性上均保持一致。

意见 16: 论文 3.2.2 部分，交互作用显著以后，重心应该放在简单效应检验上，而非事后比较。

回应: 感谢您的专业建议。在修订稿中，我们重构了结果汇报逻辑，将重心从多重比较转向简单效应分析。具体修改包括: (1). 新增了"3.2.3 简单效应分析"小节，系统呈现各组别在不同时间点间的变化情况; (2). 增加了"表 5 简单效应分析"，清晰展示各组在不同时间点间的估计边际均值差异(3.2.3 简单效应分析); (3). 调整了结果描述的重点，先报告组内时间变化，再讨论组间差异; (4). 保留了 Tukey HSD 多重比较作为补充分析(3.2.4 Tukey HSD 多重比较)。

意见 17: 作为一种前沿尝试，作者应当充分说明本研究中对 AI 心理咨询潜在风险的控制措施。例如，在人机交互过程中，如何防止 AI 系统生成可能对用户造成伤害的信息？或是当用户表现出自伤、自杀倾向等危机状况时，如何确保系统能够及时识别并采取保护措施? 这些风险控制机制的详细说明将对评估本研究和后续研究的伦理规范性和实践安全性起到至关重要的作用。

回应: 非常感谢您对于 AI 系统安全性的关心。关于 AI 心理咨询潜在风险的控制措施，我们采取了多层次的安全保障机制: (1).本研究使用的所有基座模型在面世前，已经经过严格的人类伦理道德对齐训练，此环节也是 LLM 领域的通用安全准则。(2).在基座模型测试阶段，我们专门设计了"潜在有害信息"作为评分准则中的一票否决项，确保任何可能产生危害的模型响应被及时发现并排除。(3).角色指令中明确了应对严重心理健康问题的处理流程，包括明确告知用户 AI 系统的局限性、识别高风险情况的标准和程序，以及当识别到自伤、自杀或暴力倾向时引导用户联系专业危机干预热线。(4).研究过程中，我们对人机交互进行了匿名日志分析，确保系统运行安全且未产生有害内容。

当然，尽管本研究中采取了最大限度的安全措施以防范风险，我们也认识到 AI 心理健康服务的局限性，特别是在识别和处理严重心理健康问题方面。鉴于此，我们也在讨论中就未来类似系统正式部署前进一步加强风险评估与危机干预机制:

".....本研究中 AI 系统在识别和处理严重心理健康问题方面仍存在局限。未来在正式部署和服务于可能存在精神障碍风险的人群时，应当着重加强 AI 系统在危机处理方面的能力，例如通过专门的风险评估模型、结构化的症状筛查工具以及与专业心理危机干预系统的无缝衔接等方式，进一步提升系统的安全性。同时，探索人机协作模式，在保持 AI 系统可及性的同时，将高风险案例及时转介给人类专业人员进行处理，也是未来发展的重要方向。"(4.4 局限与展望)

意见 18：论文存在较多细节性错误，例如页码不符合规范，参考文献不符合 APA 格式，建议作者认真检查、修改。

回应：感谢您的宝贵意见。我们已经按照《<心理学报>参考文献著录格式(著者-出版年制)详细要求》(https: //journal.psych.ac.cn/xlxb/fileup/0439-755X/ITEM/20220223114333.pdf)和 APA 7th Edition(https: //apastyle.apa.org/style-grammar-guidelines/references)对所有引用和参考文献进行了校对。包括对于部分通过"第一作者姓氏+年份"无法区分的引文，追加作者名/第二作者信息，以及对在线发布的文献类型(例如 *Nature Communications*、*Journal of Medical Internet Research* 和 *The Lancet Regional Health – Western Pacific* 等期刊，其文章均采用电子编号(如"123/e123")进行了逐条校对等，以确保参考文献的规范性和专业性。

第二轮

审稿人 1 意见：非常感谢作者详实的回应，作者意见基本解决或很好地回应了我之前提出的问题，在本轮审稿中我没有大的修改意见。于我而言，这是一篇非常值得期待的文章，希望早点看到文章发表。

审稿人 2 意见：

作者较好地回复了上一轮的意见，还有几个小问题，值得商榷。

意见 1：论文第 6 页，“基于简单角色指令("请扮演心理咨询师角色与用户对话")引导基座模型进行 10 轮次(一问一答)对话，形成对话评估材料”；第 7 页，“三类备选基座模型分别基于测试集话题生成 12 轮对话”。究竟是 10 轮对话还是 12 轮对话？建议作者检查一下。

回应：感谢审稿人指出此处表述问题。实验一的具体设计为：(1)测试案例数量：从 12 个主题类别中各抽取 1 条案例，形成包含 12 条测试案例的测试集；(2)对话轮次：每个基座模型针对每条测试案例进行 10 轮次对话(一问一答计为 1 轮次)；(3)评估材料总数：3 个基座模型×12 条测试案例=36 份对话评估材料。为避免混淆，我们已修改了"2.1.2 基座模型测试"和"2.2.1 模型选择"中的相关表述，明确区分了"测试集数量(12 条)"、"对话轮次(10 轮)"和"对话评估材料数量(36 份)"这三个概念。具体如下：

> *"采用分层随机抽样方法从每个主题类别中随机抽取 1 条具体案例，形成测试集(N = 12)，…，测试集构建完成后，基于简单角色指令("请扮演心理咨询师角色与用户对话")，引导三类基座模型分别就 12 条测试集案例逐条进行 10 轮次对话(一问一答计为 1 轮次)，共形成 3×12=36 份对话评估材料…"*（2.1.2 基座模型测试，第 6 页）

> *"由三位评分者在不知晓模型类型的情况下对 36 份对话评估材料进行逐条独立评分，…"*（2.2.1 模型选择，第 7 页）

意见 2：表 1 中，作者将置信区间解释为组间均值差异的 95%置信区间，这一解释模糊不清。表 1 的三类备选基座模型，两两之间的均值差异都会形成一个置信区间。那么表 1 中的置信区间代表的究竟是哪两个模型之间的均值差异呢？

回应：感谢审稿人指出本文在统计分析结果呈现规范方面的问题。原表 1 对于方差分析和事后检验的组合展示方式确实容易引起混淆。原表中所展示置信区间为最高分模型与最低分模型两两比较结果的 95%置信区间。为更加清晰地呈现分析结果，我们在修订稿中已将方差分析结果和事后检验结果分开报告：(1)修改后的表 1 仅报告各模型的描述性统计和方差分析结果；(2)新增表 2，专门报告 Tukey HSD 事后检验结果，详细展示所有模型间两两比较的均值差异及其 95%置信区间。希望这样的呈现方式能够使本研究的统计分析结果更加清晰和规范。再次感谢您的宝贵建议！

意见 3：论文第 11 页，"三个分量表的内部一致性系数(Cronbach's α)分别为 0.77(抑郁)、0.79(焦虑)和 0.76(压力)"，内部一致性系数和克伦巴赫 α 系数是两个不同的概念，不能混为一谈，建议直接报告 Cronbach's α。"本研究中各分量表分别为 0.87(抑郁)、0.90(焦虑)和 0.83(压力)"，表述不完整。

回应：感谢审稿人的专业指正。在修订稿中，我们对此类表述问题进行了全面检查和修改。相关内容如下：

“...使用抑郁-焦虑-压力量表简式版(DASS-21; Lovibond & Lovibond, 1995)进行测量。...。本研究中，各子量表的 Cronbach's α 系数分别为 0.87(抑郁)、0.90(焦虑)和 0.83(压力)。”、“...使用孤独感简式量表(SSL; Hughes et al., 1993)进行测量，...。本研究中该量表的 Cronbach's α 系数为 0.86。”（3.1.3 测量工具，第 12 页）

意见 4：论文仍存在较多细节性问题，例如，表 3-表 5 中的星号未上标；18 页，“与先前关于数字心理健康干预有效性的研究发现一致(Chan & and Li, 2023; Karyotaki et al., 2021; J. Lee et al., 2024)”，参考文献的引用不规范等。建议作者对论文仔细检查、修改。

回应： 感谢审稿人指出本文在统计报告规范和引文方面的细节问题。我们已对全文进行了系统检查和修改：(1)统一了表 3-5 中所有显著性标记的上标格式；(2)通过检查 EndNote 引用风格结合人工核查，修正了原文中引用格式类错误，如"Chan & and Li, 2023"中"&"符号后多余的"and"、文献年份和第一作者相同时的追加规则等。再次感谢审稿人的细致审阅！

第三轮

编委意见：构建基于大语言模型的自助式 AI 心理咨询系统具有重要的工程心理学意义，作者也很好地回答了评审专家的意见，建议修改后发表。从科学心理学角度，仍然有一些细节需要完善，具体建议如下：

意见 1： 摘要和引言开篇、文章结论的逻辑还不够清晰和聚焦。例如，全球心理问题的严重性与本文想要建构的普通健康人群 AI 心理咨询系统不是同一个问题，作者也没有招募真正有心理健康问题的人作为被试。这里面涉及一些重要的健康心理学元问题——心理健康教育与咨询的目的究竟是为了促进广大民众的生活幸福和全面发展，还是治疗少数有心理健康问题者的精神疾病。从本文所用一般模型、研究对象和研究结果来看，显然作者聚焦的是前者。

回应： 感谢编委针对本文研究定位阐述方面提出的宝贵意见。我们已在修订后的论文中对研究背景的逻辑主线进行了系统调整。修订后的研究背景相关内容如下：

“提升大众心理健康水平 、促进个体全面发展，是构建和谐社会与实现健康中国战略的重要组成部分(中华人民共和国国家卫生健康委员会, 2019)。在快节奏的现代生活中，人们普遍面临工作与学业压力、焦虑、抑郁和孤独等心

理困扰。研究表明，即使未达到临床诊断标准的轻度心理困扰也会显著影响个体的生活质量和工作效率(De Oliveira et al., 2023; Hardy et al., 2003; Karani et al., 2021)。及时有效的心理支持对于维护情绪稳定、增强社会适应能力和提升民众整体生活幸福感至关重要。然而，据 Sun 等人(2024)统计，中国每十万人口对应的精神健康专业人员仅有不到 3 人。传统心理咨询服务由于资源稀缺(Saxena et al., 2007)、成本高昂(Lu et al., 2021)及地域分布差异(Patel et al., 2016)等因素，难以满足广大民众日益增长的心理支持需求。这一"供给鸿沟"凸显了开发低门槛、高可及性的心理健康促进工具的紧迫性。"（1.1 研究背景，首段）

与之对应地，论文摘要及其他涉及研究目标人群的表述也进行了相应修改和标注，以明确本研究的价值定位。再次感谢您的宝贵意见！

意见 2：研究 2 不同变量的实验结果不尽相同，孤独感、压力的结果差异尤其有意义。因此建议作者在方法部分详细报告量表的条目样例和概念定义，并在大前言和小前言部分对不同心理健康变量的概念进行介绍（如为什么焦虑、抑郁不是压力），并提出明确的研究假设。同时，拟人化 AI 心理咨询对孤独感、压力指标的不同效应，可能具有文化特异性，是否人际压力较大的集体主义或中国文化才更回避真人、偏好机器人——这一点需要在讨论（尤其是研究局限和展望）部分加以说明，并注明参考文献。

回应：感谢编委的宝贵建议。为使读者更好地理解本研究发现的差异化效应模式，我们已在修订稿中就理论阐释、方法描述和文化特异性讨论三个方面进行了补充。在理论层面，我们新增了 1.2.4 小节"关键心理健康指标的选择"。系统阐述了抑郁、焦虑、压力和孤独感的概念及其在心理机制上的独特差异。通过引用前任工作，我们详细解释了焦虑的干预过程主要基于认知评估系统，而压力反映的是个体与环境的交互适应过程，孤独感则直接反映社会连接的质量。相关内容如下：

"本研究选择抑郁（depression）、焦虑（anxiety）、压力（stress）和孤独感（loneliness）作为核心评估指标。一方面，上述心理困扰在普通人群中较为常见，具有良好的代表性；另一方面，其在心理机制上呈现独特差异，为探索 AI 心理咨询的差异化效应提供了良好的研究框架。具体而言，抑郁主要涉及情感调节系统的功能障碍，表现为持续的情绪低落、兴趣丧失和自我价值感下降(Beck et al., 2021)，其改善通常需要通过行为激活和情感重新体验实现，这一过程往往伴随波动性和复发风险。焦虑则主要基于认知评估系统，表现为对未来威胁的过度担忧和回避行为(Craske et al., 2018; Craske et al., 2019)。与抑

郁不同，焦虑的改善主要通过认知层面的威胁评估修正来实现，且认知技能一旦掌握往往具有较好的稳定性(Breit et al., 2024; Hofmann et al., 2012)。压力反映的是个体与环境的交互适应过程，当环境要求超出个体应对资源时产生主观压力体验(Folkman et al., 1986; Lovibond & Lovibond, 1995)。压力缓解主要依赖问题解决能力的提升，但需要注意的是，社会评价本身就是重要的压力源(Dickerson et al., 2004)，这意味着在自我暴露和问题讨论情境中，社会评价威胁可能影响干预效果。孤独感则直接反映社会连接的质量，是个体期望社会关系与实际社会关系差异产生的主观体验(Hughes et al., 1993; Perlman & Peplau, 1981)。与其他指标不同，孤独感的改善更多依赖于社会存在感和人际连接体验的获得(Cacioppo et al., 2015)，这使得孤独感可能对人际互动的真实性较为敏感。上述机制差异暗示了不同指标可能对 AI 心理咨询系统的特定设计要素表现出差异化响应模式，为系统优化和个性化干预提供了理论基础。……"（1.2.4 关键心理健康指标的选择，首段）

在方法部分，我们在 3.1.3 测量工具部分增加了详细的量表条目示例和概念定义：

"……DASS-21 包含三个子量表：抑郁子量表主要测量快感缺失、绝望和贬低生活价值等核心症状（条目示例："我对任何事情都提不起兴趣"、"我觉得生活毫无意义"）；焦虑子量表：用于评估过度生理唤醒、情境性焦虑和主观焦虑体验（条目示例："我觉得很难放松自己"、"我担心一些让自己感到恐慌或出丑的场合"）；压力子量表：测量难以放松、神经紧张、易怒和过度反应等（条目示例："我发现自己很难放松下来"、"我觉得自己精疲力尽"）。……"（3.1.3 测量工具，首段）

"……使用孤独感简式量表(SSL; Hughes et al., 1993)进行测量，该量表基于 UCLA 孤独感量表理论框架，将孤独感定义为个体期望的社会关系与实际获得的社会关系之间的差异所产生的不愉快主观体验，共包含 3 个条目（"我觉得我缺乏陪伴"、"我感到被排斥"、"我感到被孤立"）。各条目采用 1-5 点计分(1=几乎从不，2=很少，3=有时，4=经常，5=几乎总是)，量表得分范围为 3-15 分，分数越高表示孤独感越强。……"（3.1.3 测量工具，第 2 段）

同时，修订后的论文在实验 1 和实验 2 开头均提出了明确的研究假设：

"……基于零样本学习和思维链提示策略的理论优势，本实验提出以下假设：H1：经过思维链提示策略优化的大语言模型相比简单角色指令驱动的模型，在心理咨询对话质量方面将表现出显著改善。"（2 实验 1: 构建基于大语言模型的自助式 AI 心理咨询系统，首段）

“……基于实验一证实的提示工程优化效果和前述理论分析，本实验提出以下假设：H2：自助式 AI 心理咨询系统能够显著改善参与者的抑郁、焦虑、压力和孤独感；H3a：焦虑情绪的改善效果将表现出比抑郁、压力和孤独感更好的持续性；H3b：AI 咨询师的非拟人化设计对于压力的改善效果将显著优于拟人化设计；H3c：AI 咨询师的拟人化设计对于孤独感的改善效果将显著优于非拟人化设计”（3 实验 2：基于随机对照试验的自助式心理咨询效果评估，首段）

关于文化特异性的讨论，我们在 4.4 局限与展望部分新增了专门的论述，并建议未来开展跨文化比较研究：

“……本研究中拟人化设计对压力和孤独感的差异化影响，可能源于中国集体主义文化下的特殊心理机制。研究表明，东亚民众倾向于采用一种关注“场域”和情境因素的整体性认知模式(Ji et al., 2000; Morris & Peng, 1994; Peng et al., 1997)。这种集体主义型认知在强调人际重要性的同时，也可能导致更强的社会评价压力(Hofstede et al., 1990; Huang et al., 2020; Huang et al., 2022)。因此，非拟人化机器人可能通过剥离交互中的社会属性，创造了一个低评价威胁的“非社会性场域”，从而让用户在探讨压力源时不必顾及“人情”与“面子”(Hwang, 1987)等集体主义构念，使得交流更为开放。然而，该模式在个人主义文化中可能有所不同，未来的跨文化研究应进一步检验其普适性，以开发更具文化适应性的 AI 心理支持系统。”（4.4 局限与展望，第三段）

意见 3：结果报告还可以更规范。例如，考虑到变量、数值长度不一，表格内容是否统一左对齐；图上需要标注显著性、并补充图注，以便读者更可以更好理解统计的显著性和字母缩写的含义；正文中的 p 值大于 0.001 时，需要完整报告小数点后的三位数，请通篇检查。

回应：感谢编委关于结果报告规范性方面的建议。已进行了全面的格式优化。我们在修订稿中对论文的报告格式进行了通篇检查和修正，确保符合学报的撰写规范，包括将所有大于 0.001 的 p 值都完整报告小数点后三位数。同时我们也调整了表格的格式设置，统一采用左方式排版以提高整体的可读性。针对涉及统计检验结果展示的图 4（简单斜率分析图），考虑到 4（亚组）×3（重复测量）的实验设计中，仅在每个测量时间点就会产生 6 组两两比较结果，在图上直接标注显著性差异会造成视觉混乱。鉴于此，我们采用了图注说明的方式详细解释误差线的含义（95%置信区间）以及各组别缩写的具体指代，确保读者能够正确理解图形信息。同时将统计显著性的具体数值结果在正文中进行详细报告。

再次感谢编委及全体审稿人的辛勤付出与专业指导，为本研究及相关学术领域的发展提供了宝贵支持！

编委意见：建议录用。

主编意见：同意录用。